

El Clasificador

Aprendizaje por Refuerzo para la detección de correo anómalo

Sistemas Inteligentes
Universidad de La Frontera

Informe breve • Aplicación web: *El Clasificador*

Resumen. Este trabajo presenta una aplicación web educativa que enseña Aprendizaje por Refuerzo (RL) a través de un caso de detección de anomalías: separar correo legítimo de correo anómalo (spam y suplantación, *phishing*). En lugar de un tutorial abstracto, la app muestra a un agente de Q-learning (un clasificador recién instalado en una sala de correo) fracasar, aprender y finalmente superar a un conjunto de reglas razonables. Cada concepto formal (estado, acción, recompensa, política) aparece primero como un hecho físico y solo después como una ecuación. Todo el modelo se entrena en el navegador, sin backend ni dependencias.

1. El problema, y por qué es Aprendizaje por Refuerzo

Clasificar correo es tomar, miles de veces al día, una decisión bajo incertidumbre: **aceptar** (al buzón) o **descartar** (a la papelera), sin conocer con certeza el contenido. Los errores no son simétricos: dejar pasar spam es una molestia. **Descartar una carta legítima es un daño irreversible.** Esa asimetría de costos, sumada a la naturaleza secuencial del flujo (la reputación de un remitente evoluciona con lo que ha enviado antes), es exactamente la clase de problema que el RL modela de forma natural: un agente que aprende una política por interacción con un entorno, guiado solo por una señal de recompensa [1].

A diferencia del aprendizaje supervisado, aquí no hay un maestro que entregue la etiqueta correcta de cada correo antes de decidir. Hay un número, la recompensa, que llega *después* de actuar, cuando se revela la verdad, y que empuja al agente a mejorar. El costo asimétrico, además, no hay que codificarlo como una regla: vive dentro de la función de recompensa, y la política conservadora emerge.

¿Por qué esto es detección de anomalías? La detección de anomalías identifica eventos poco frecuentes que se desvían de un patrón esperado, mayormente “normal” [3]. El correo anómalo de este trabajo encaja ahí: spam y suplantación son minoría (30 % y 10 % del tráfico, ver §4) frente al correo legítimo, y se definen precisamente por desviarse de las señales típicas de un remitente de confianza: contacto nuevo o reputación en caída, urgencia inusual, enlaces sin patrón previo, horario atípico. La suplantación es el caso límite: no es una categoría aparte con reglas propias, es la *cola* de la distribución, camuflada dentro de lo que parece normal (buena reputación, remitente conocido). Detectarla exige aprender la combinación de señales, no una sola regla. Es exactamente lo que el agente hace.

2. El modelo: un proceso de decisión (MDP)

Formalizamos la sala de correo como una tupla (S, A, R, T, γ) .

Estado (S). Cada correo se describe con cinco variables observables, dibujadas sobre el sobre:

Variable	Valores	Representación visual
remitente	conocido / desconocido	sello relleno o hueco
reputación	bueno / neutro / malo	color del sello (ámbar / gris / negro)
enlaces	0 / 1 / varios	marcas de anzuelo
urgencia	baja / alta	cinta roja
hora	laboral / madrugada	matasellos (sol / luna)

Cardinalidad: $2 \times 3 \times 3 \times 2 \times 2 = 72$ estados. La discretización se eligió para ser legible, no óptima: permite representar toda la tabla Q como un archivador de 72 sobres que el usuario puede leer de un vistazo.

Acciones (A). {aceptar, descartar}.

Recompensa (R). Es literalmente la matriz de confusión, con costo asimétrico:

	era legítimo	era spam
aceptar	+5	−2
descartar	−20	+3

Descartar una carta real cuesta diez veces más que dejar pasar spam. Ese −20 es el corazón del modelo.

Transición (T). Tras cada decisión se revela la etiqueta verdadera y el entorno actualiza la reputación del remitente: sube un nivel con correo legítimo (lentamente: dos aciertos por nivel), baja con spam (un envío por nivel). Así el estado de un remitente evoluciona con la trayectoria.

Descuento ($\gamma = 0,9$).

3. El algoritmo: Q-learning tabular

El agente estima $Q(s, a)$, el valor a largo plazo de tomar la acción a en el estado s , y lo corrige tras cada transición (s, a, r, s') [1, 2]:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \cdot [r + \gamma \cdot \max_{a'} Q(s', a') - Q(s, a)]$$

La actualización es *off-policy*: el objetivo usa $\max_{a'} Q(s', a')$, la mejor acción futura, aunque el agente aún esté explorando. Hiperparámetros: $\alpha = 0,1$, $\gamma = 0,9$, y una política ε -greedy con $\varepsilon : 1,0 \rightarrow 0,05$ (decaimiento exponencial sobre 5 000 episodios). No se usa una red neuronal (DQN): el estado es diminuto, y una tabla, a diferencia de una red, se puede visualizar, que es el punto de la app.

4. Los datos: un entorno con trampas

El correo es sintético y se muestrea de cuatro poblaciones con características estocásticas (por eso ninguna señal aislada clasifica perfecto): legítimo cotidiano (45 %), legítimo nuevo (15 %), spam burdo (30 %) y suplantación (10 %). Un episodio es una jornada de 50 sobres de 15 remitentes fijos. El entorno tiene tres trampas deliberadas:

- **El legítimo nuevo** castiga la regla “descartar si el remitente es desconocido”: rompe cartas reales de clientes nuevos.

- **La suplantación** castiga la regla “confiar en el remitente conocido”: llega desde una dirección conocida y de buena reputación. Solo la delatan los enlaces.
- **El remitente comprometido** (3 de los 15) empieza enviando correo legítimo y, a mitad de la jornada, pasa a la suplantación. Impide memorizar “confío en X”.

5. Resultados

Se evaluaron cinco estrategias sobre 500 episodios (25 000 sobres) del mismo flujo (el entorno es determinista dado su semilla, y su flujo no depende de la acción, lo que hace la comparación exacta):

Estrategia	R/ep	Cartas rotas	Suplant. atrapada	Aciertos
Aceptar todo	108.9	0	0 %	60 %
Descartar todo	−536,2	14 918	100 %	40 %
Regla: descartar si desconocido	−114,6	4 927	19 %	49 %
Regla: descartar si mala reputación	176.2	0	13 %	87 %
Política aprendida (RL)	193.0	53	40 %	94 %

La política aprendida obtiene la mayor recompensa y atrapa tres veces más suplantación que la regla de reputación (40 % vs. 13 %), rompiendo muy pocas cartas reales. La clave: la regla de reputación reacciona (solo descarta después de que el daño bajó la reputación, y no ve venir al remitente comprometido, cuya reputación aún es buena al atacar), mientras que la política aprendida anticipa, desconfiando de la combinación de señales (sello ámbar más varios anzuelos más urgencia) antes que del historial.

La parte honesta. La política aprendida acepta *más* spam que la regla dura, porque le enseñamos a temerle al −20. No es un defecto: es la función de recompensa haciendo exactamente lo que le pedimos. La app lo declara en lugar de esconderlo.

6. Exploración vs. explotación

La app permite forzar $\varepsilon = 0$ desde el primer episodio. El agente resultante explota su primera corazonada de inmediato: su curva de recompensa arranca alta (no paga el precio de equivocarse al azar) pero se estanca. Atrapa solo un $\sim 23\%$ de la suplantación (contra $\sim 40\%$ del agente que exploró) y deja pasar más spam, porque nunca probó descartar los sobres ambiguos que parecían legítimos. El agente que explora paga caro al inicio (su curva se hunde en negativo) y por eso descubre después lo que la primera corazonada no vio. Es el dilema exploración-explotación, mostrado en una sola curva.

7. Limitaciones

- **Datos sintéticos.** El agente aprendió sobre un mundo diseñado por nosotros: proporciones, señales y la recompensa −20 son elecciones. Ningún resultado aquí prueba algo sobre correo real.
- **¿MDP o bandit contextual?** En este entorno la reputación se actualiza según la etiqueta verdadera, no según la acción del agente. Estrictamente, la acción no cambia el estado siguiente, por lo que el problema se acerca más a un *bandit contextual con contexto no estacionario*. El interés secuencial reside en que el estado de un remitente evoluciona con la trayectoria (el remitente comprometido). Preferimos señalarlo a exagerar el rol de γ .

- **Alternativas.** Un filtro bayesiano o supervisado, con un buen corpus etiquetado, probablemente superaría a RL en exactitud pura [4, 5, 3]. Su debilidad es justamente el costo asimétrico y el desbalance de clases, que hay que inyectar a mano. Este trabajo no afirma que RL sea la mejor solución: muestra cómo se piensa el problema en términos de RL.

8. Conclusiones

El Clasificador logra el objetivo del enunciado: explica los fundamentos del Aprendizaje por Refuerzo (agente, entorno, estado, acción, recompensa, política), el proceso de aprendizaje por recompensas y el algoritmo de Q-learning, anclando cada concepto a un caso concreto y realista de detección de anomalías. La visualización (la compuerta que se inclina, el archivador de 72 sobres que se colorea, la papelería que conserva sus cicatrices) convierte conceptos abstractos en objetos observables. Y, sobre todo, el trabajo es honesto acerca de sus límites, lo que a nuestro juicio demuestra más comprensión que reportar una cifra de exactitud sin contexto.

Referencias

- [1] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press.
- [2] Watkins, C. J. C. H., & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3-4), 279-292.
- [3] Pang, G., Shen, C., Cao, L., & van den Hengel, A. (2021). Deep learning for anomaly detection: A review. *ACM Computing Surveys*, 54(2).
- [4] Sahami, M., Dumais, S., Heckerman, D., & Horvitz, E. (1998). A Bayesian approach to filtering junk e-mail. *AAAI Workshop on Learning for Text Categorization* (Tech. Report WS-98-05).
- [5] Cormack, G. V. (2008). Email spam filtering: A systematic review. *Foundations and Trends in Information Retrieval*, 1(4), 335-455.