

El Clasificador

Aprendizaje por Refuerzo para la detección de correo anómalo

Sistemas Inteligentes
Universidad de La Frontera

1. La idea y el flujo de la app

La app tiene tres pantallas y el usuario las recorre en orden.

1. La sala de correo (el problema). El usuario ve llegar sobres uno a uno. Cada sobre muestra pistas dibujadas sobre sí mismo. El sello puede estar relleno o hueco, según si el remitente es conocido o no. El color del sello indica la reputación (ámbar, gris o negro). Hay marcas de anzuelo según la cantidad de enlaces, una cinta roja si hay urgencia, y un matasellos de sol o luna según la hora de envío. El usuario puede decidir él mismo si aceptar o descartar cada sobre antes de ver actuar al agente, y al instante se revela si el sobre era legítimo o no. Esta pantalla muestra la idea central: clasificar correo es decidir sin certeza, y los errores no cuestan lo mismo en ambas direcciones. Descartar una carta real es mucho más grave que dejar pasar spam.

2. El archivador de 72 sobres (lo que el agente sabe). Aquí se ve lo que el agente aprendió. Es un archivador con 72 casillas, una por cada combinación posible de las cinco señales, y cada casilla se va coloreando según qué tan seguro está el agente de aceptar o descartar en esa situación. El usuario puede pasar el cursor sobre cualquier casilla y ver el valor aprendido para ese tipo de correo. Esto reemplaza la tabla Q abstracta del algoritmo de Q-learning [2] por algo que se puede mirar y explorar.

3. La jornada y la comparación (el aprendizaje ocurriendo). Esta es la parte interactiva principal. El usuario dispara una jornada de 50 correos y ve en tiempo real una compuerta que se inclina hacia aceptar o descartar según la decisión del agente, y una papelera que va acumulando marcas visibles por cada carta legítima rota por error. Una curva de recompensa acompaña el proceso episodio a episodio. El usuario puede:

- Comparar la política aprendida contra reglas fijas (aceptar todo, descartar todo, descartar si el remitente es desconocido, descartar si la reputación es mala) sobre el mismo flujo de correo, para ver quién causa menos daño y detecta más suplantación.
- Apagar la exploración desde el inicio y ver cómo el agente se queda con su primera impresión. Su curva arranca más alta pero se estanca, y detecta mucha menos suplantación que un agente que sí exploró.
- Observar al remitente comprometido, una cuenta que envía correo legítimo por un tiempo y luego cambia a suplantación, para ver si el agente reacciona a tiempo o sigue confiando por costumbre.

En conjunto, el flujo de la app muestra sin necesitar fórmulas las ideas centrales del Aprendizaje por Refuerzo [1]: que la decisión ocurre sin certeza, que el costo de los errores no es igual en ambas direcciones, que el conocimiento del agente se puede ver e inspeccionar, y que explorar antes de aprovechar tiene un costo al inicio pero rinde después.

2. Por qué es detección de anomalías

La detección de anomalías identifica eventos poco frecuentes que se desvían de un patrón esperado [3]. El spam y la suplantación son minoría frente al correo legítimo (30 % y 10 % del tráfico) y se definen por alejarse de las señales típicas de un remitente de confianza. La suplantación es el caso más difícil. Llega desde una dirección conocida y de buena reputación, y solo la delatan los enlaces. No es una categoría con reglas propias. Es un caso raro escondido dentro de lo que parece normal, y detectarlo exige combinar varias señales en vez de aplicar una sola regla.

3. Resultados

Se probaron 500 episodios (25 000 sobres) con el mismo flujo de correo. La política aprendida logra la mejor recompensa promedio y el mejor balance entre daño y detección:

Estrategia	R/ep	Cartas rotas	Suplant. atrapada	Aciertos
Aceptar todo	108.9	0	0 %	60 %
Descartar todo	−536,2	14 918	100 %	40 %
Descartar si desconocido	−114,6	4 927	19 %	49 %
Descartar si mala reputación	176.2	0	13 %	87 %
Política aprendida (RL)	193.0	53	40 %	94 %

La política aprendida atrapa tres veces más suplantación que la mejor regla fija (40 % contra 13 %) y rompe muy pocas cartas reales. Esto pasa porque anticipa combinaciones de señales sospechosas en vez de esperar a que la reputación ya haya caído. Como parte honesta, la política aprendida deja pasar algo más de spam que una regla dura. No es un defecto. Es el resultado directo de haberle enseñado a temer el costo alto de romper correo real.

4. Limitaciones

Los datos son sintéticos. Las proporciones y los castigos son decisiones de diseño, así que ningún resultado aquí prueba algo sobre correo real. Además, en este entorno la reputación cambia según la etiqueta verdadera y no según la acción del agente. Por eso el problema se parece más a un proceso de decisión con contexto cambiante que a un caso secuencial estricto. Lo secuencial aparece porque el estado de un remitente cambia con su historial, sobre todo en el caso del remitente comprometido. Un filtro supervisado o bayesiano bien entrenado, como los estudiados en la literatura de filtrado de spam [4, 5], probablemente sería más exacto que RL. Su debilidad está justo en el costo asimétrico y en el desbalance de clases, algo que aquí se resuelve de forma natural con la recompensa.

5. Uso adecuado de referencias bibliográficas

Las fuentes citadas en este trabajo se usan solo para apoyar afirmaciones puntuales, no para copiar contenido. Sutton y Barto [1] y Watkins y Dayan [2] respaldan la descripción del agente y de la regla de actualización de Q-learning. Pang et al. [3] respalda la definición de detección de anomalías usada en la sección 2. Sahami et al. [4] y Cormack [5] respaldan la comparación con filtros supervisados y bayesianos en la sección de limitaciones. Ninguna cita reemplaza el análisis propio del trabajo, y las ideas de cada fuente se explican con palabras propias.

6. Conclusión

El Clasificador cumple su objetivo educativo con tres pantallas interactivas: la sala de correo, el archivador de 72 sobres y la jornada comparada. Ahí se ve cómo un agente aprende una política mejor que las reglas fijas frente a errores asimétricos y una anomalía escondida dentro de lo normal. La app es honesta sobre sus límites, y eso vale más que mostrar una cifra de exactitud sin contexto.

Referencias

- [1] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2.^a ed.). MIT Press.
- [2] Watkins, C. J. C. H., & Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3-4), 279-292.
- [3] Pang, G., Shen, C., Cao, L., & van den Hengel, A. (2021). Deep learning for anomaly detection: A review. *ACM Computing Surveys*, 54(2).
- [4] Sahami, M., Dumais, S., Heckerman, D., & Horvitz, E. (1998). A Bayesian approach to filtering junk e-mail. *AAAI Workshop on Learning for Text Categorization* (Tech. Report WS-98-05).
- [5] Cormack, G. V. (2008). Email spam filtering: A systematic review. *Foundations and Trends in Information Retrieval*, 1(4), 335-455.